100만개 문서를 처리하는 100만개 솔루션 개발하기

LLM 위에 무엇을 쌓아야 production이 되는가 – Data Harness Engineering 사례

정한얼 / 원라인에이아이

CEO 클로드 코드 클럽 첫번째 오프라인 세미나

대한민국 금융사 AX 1등 기업, 원라인에이아이

Our Products

챗봇 · 에이전트 · 데이터셋 · 내재화 사업

Chatbot

01 · CHATBOT

챗봇

금융 실무 질의에 출처와 함께 답하는 사내용 챗봇.

- 금융 챗봇
- 공시 챗봇 — KRX·DART 그라운딩

Agent

02 · AGENT

에이전트

자동 리서치·자동 절세 자문·자동 문서 작성 에이전트.

- 데일리 인사이트 · 리서치 에이전트
- 절세상담 에이전트
- 문서 자동화 DOVI

Dataset

03 · DATASET

데이터셋

SQL 한 줄로 답이 나오는 정형 금융 데이터셋.

- IPO 데이터셋
- 비상장사 KODATA
- 글로벌 뉴스·공시·ETF

Internalization

04 · INTERNALIZATION

내재화 사업

금융사 내부망에 LLM·RAG·운영체계를 한 번에 구축.

- OLAF 금융특화 LLM
- AX 내재화 솔루션
- 프리미엄 AX 교육

금융 특화

범용 LLM이 풀지 못하는 금융 도메인의 추론·규정·데이터 결합을 직접 다룹니다.

4주 도입

레고처럼 조립 가능한 모듈로 PoC가 아닌 운영 가능한 서비스를 4주 안에 인계합니다.

내부망 운영

데이터·모델·로그가 외부로 나가지 않습니다. 금융권 컴플라이언스 안에서 동작합니다.

이 세션에서 얘기하는 것

이 세션에서 얘기하는 것

✓ 클로드 코드 말고 코덱스 쓰세요...

이 세션에서 얘기하는 것

- ✓ LLM 코어 위에 무엇을 쌓아야 production이 되는가
- ✓ "엣지케이스가 100만 개"인 문제를 어떻게 시스템화 하는가
- ✓ 경영자·기획자가 고민해봐야 할 마인드 스킬셋

다루지 않는 것

- ✗ 프롬프트 엔지니어링 팁
- ✗ 어떤 LLM 모델이 더 좋은가
- ✗ RAG / Agent 프레임워크 비교

들어가기 전

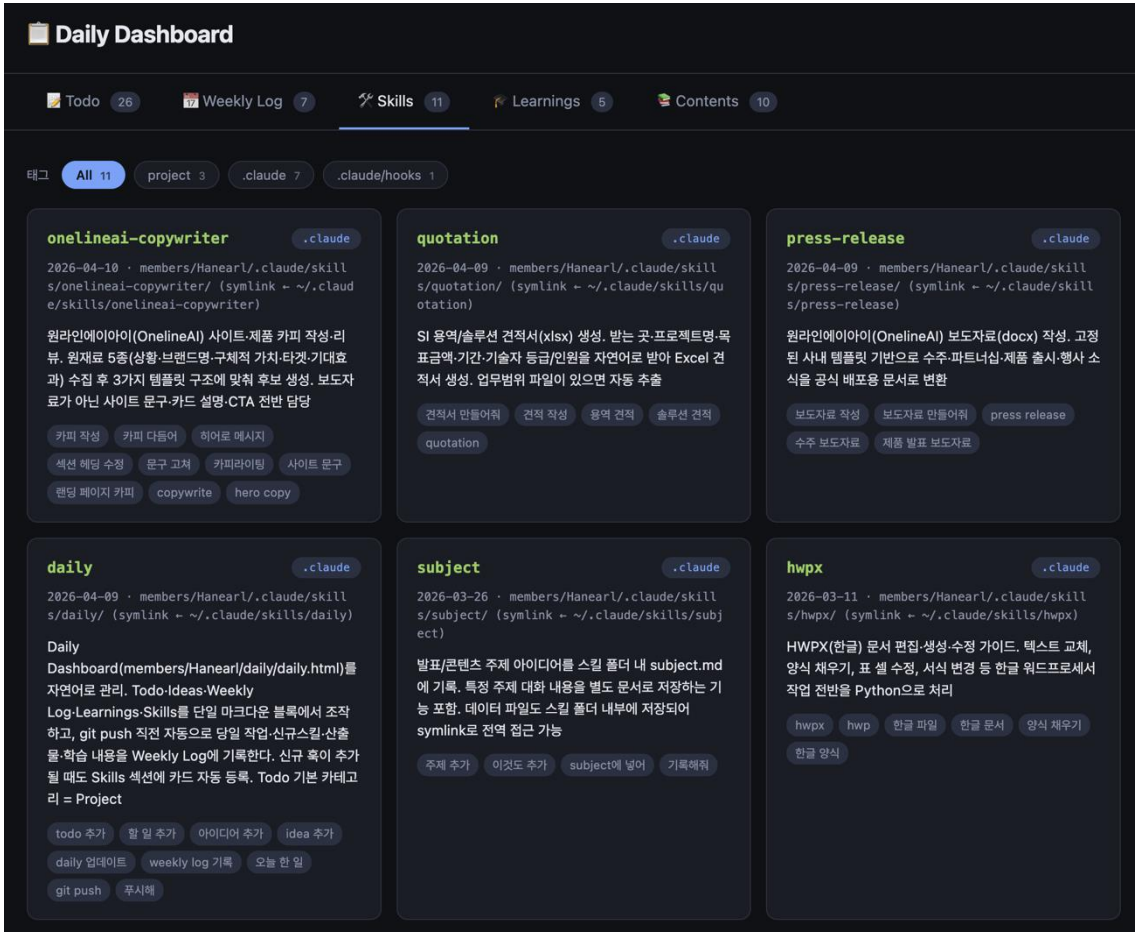

- 견적서 자동화 (quotation)
- 기사 작성 스킬 (press-release)
- 사이트, 제품 카피 작성 스킬 (copywriter)
- 콘텐츠, 아이디어 스킬 (subject)
- 한글 작성 스킬 (hwpx)
- 데일리 루틴 관련 대시 보드 (daily)

대표자 스킬..

SECTION 01

Problem framing

무엇이 문제였나

> *"100만 보고서는 100만 엣지케이스를 만든다"*

신동아건설 주식회사

재 무 제 표 에 대 한

감 사 보 고 서

제 48 기

2024년 01월 01일 부터

2024년 12월 31일 까지

제 47 기

2023년 01월 01일 부터

2023년 12월 31일 까지

삼일회계법인

주석

제 48 기 : 2024년 12월 31일 현재

제 47 기 : 2023년 12월 31일 현재

신동아건설 주식회사

1. 당사의 개요

신동아건설 주식회사(이하 "당사")는 1977년 12월 7일에 설립되어 주택사업, 토목, 건축, 포장 등 건설업과 부동산임대업을 주요 사업으로 하고 있으며, 경기도 용인시 기흥구 죽전로 7 에 본사를, 서울시 용산구 이촌로에 지점을 두고 있습니다.

보고기간종료일 현재 납입자본금은 25,916백만원이며, 당사의 주요 주주의 구성내역은 다음과 같습니다.

주 주 명	소유주식수	비율	당사와의 관계
김용선	3,459,621주	66.75%	최대주주
김세준	661,663주	12.76%	특수관계인
(주)일해토건	981,648주	18.94%	특수관계인
기타	80,342주	1.55%	-
합계	5,183,274주	100.00%	

한편, 당사는 2025.01.22일 서울회생법원으로 부터 "채무자 회생 및 파산에 관한 법률 제34조 제1항 제2호"에 따른 회생절차 개시 결정을 받았으며, 제48기 정기주주총회를 개최하지 않아 당사의 재무제표는 승인되지 못하였습니다.

2. 중요한 회계정책

재무제표의 작성에 적용된 중요한 회계정책은 아래에 제시되어 있습니다. 이러한 정책은 별도의 언급이 없다면, 표시된 회계기간에 계속적으로 적용되었습니다.

Task

✓ 감사보고서/사업보고서 주석사항을 정형화 하기

Challenge

✗ N만개 회사의 N만개 다른 형식의 문서를 어떻게
단일 스키마로 정형화 할 것인가

✗ 바로 context가 터지는 문서 길이

✗ 데이터 정합성 검증은?

DART Dashboard audit business 2025 Overview Reports Validations Memos Context Prompts Jobs Codes Data Preview | Reports(V) Validations(V) Codes(V) Preview(V) admin admin Logout

3

Source HTML

HTML Size: 91.0KB | Sections: 20

2) 전기

사업 지역	사업장 구분	PF종류	신용보강 종류	보증 한도 (전체)	부담률 (당사)	보증 금액 (당사)	채무자	특수관계자 여부	채권기관 종류	대출잔액(당사)		대출 기간	만기
										당기	전기		
서울시	공동주택	본PF	연대보증	937,517	100%	937,517	공성재건축정비 사업조합	해당없음	기타	937,517	937,517	22.03~ 24.02	24.0
단독사업 계				937,517		937,517				937,517	937,517		

(2) 보고기간종료일 현재 12건의 기타사업 관련 PF(대출) 보증 내역은 다음과 같습니다. PF 보증 관련 일부 약정에는 차주가 금융계약
하는 경우, 시공사의 신용등급이 하락하는 경우 등이 발생시 577,126백만원(전기말 403,716백만원)의 기한이익상실 사유가 있습니다

1) 당기

사업 지업	사업장 구분	PF종류	신용보강 종류	보증 한도 (전체)	부담률 (당사)	보증 금액 (당사)	채무자	특수 관계자 여부	채권기관 종류	대출잔액(당사	
										당기	
경기도 김포시	공동주택	본PF	연대보증	3,456,912	100%	3,456,912	(주)두드림	해당없음	은행	3,456,912	
경기도 성남시	공동주택	브릿지론	이자지급보증	4,200,000	100%	4,200,000	수진지역주택조합	해당없음	은행	4,200,000	4,
경상남도진주시	공동주택	본PF	책임준공 이자지급보증	52,823,682	100%	52,823,682	케이엔진주제일차(주)	해당없음	대주단	52,823,682	5
경기도 의정부시	공동주택	본PF	책임준공	79,000,000	100%	58,326,000	케이아이에스대체제십사차(주)	해당없음	대주단	58,326,000	42
경기도 의정부시	공동주택	본PF	책임준공	40,500,000	100%	36,259,000	(주)케이에스와이개발	해당없음	대주단	36,259,000	24

▶ Extraction History

Extraction Data Latest

Score: 1.0000 Severity: CLEAN

Row Coverage: 1.0000 Cell Accuracy: 1.0000 HTML Rows: 65 JSON Records: 84

Ungroup Columns 2 column pairs grouped

ype	guarantee_category	guarantee_limit	guarantee_limit	ofr_enp	rel_ctt
	부동산 PF(대출) 보증 - 기타사업 - 단독사업	52823682000	52823682	케이엔진주제일차(주)	책임준공 및 이자
	부동산 PF(대출) 보증 - 기타사업 - 단독사업	52823682000	52823682	케이엔진주제일차(주)	책임준공 및 이자
	부동산 PF(대출) 보증 - 기타사업 - 단독사업	79000000000	79000000	케이아이에스대체제십사차(주)	책임준공
	부동산 PF(대출) 보증 - 기타사업 - 단독사업	79000000000	79000000	케이아이에스대체제십사차(주)	책임준공
	부동산 PF(대출) 보증 - 기타사업 - 단독사업	40500000000	40500000	(주)케이에스와이개발	책임준공
	부동산 PF(대출) 보증 - 기타사업 - 단독사업	40500000000	40500000	(주)케이에스와이개발	책임준공
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	49748442000	49748442	(주)모아종합건설	연대보증
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	49748442000	49748442	(주)모아종합건설	연대보증
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	31927136000	31927136	그린시티송산(주)	연대보증
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	31927136000	31927136	그린시티송산(주)	연대보증
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	33934000000	33934000	태영건설 외	책임준공
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	33934000000	33934000	태영건설 외	책임준공
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	105000000000	105000000	(주)모아종합건설	책임준공 및 자금
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	105000000000	105000000	(주)모아종합건설	책임준공 및 자금
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	56100000000	56100000	브레인시티10피에프브이(주)	책임준공 및 연대
	부동산 PF(대출) 보증 - 기타사업 - 컨소시엄	56100000000	56100000	브레인시티10피에프브이(주)	책임준공 및 연대

Total rows: 84

```html
  <TD width='81' height='23' align='RIGHT'>1,231,231 </TD>
</TR>
<TR height='30'>
  <TD width='175' height='23'> 대표이사 등</TD>
  <TD width='78' height='23' align='RIGHT'>550,000 </TD>
  <TD width='78' height='23' align='RIGHT'>- </TD>
  <TD width='78' height='23' align='RIGHT'>2,842 </TD>
  <TD width='81' height='23' align='RIGHT'>419,437 </TD>
  <TD width='81' height='23' align='RIGHT'>- </TD>
  <TD width='81' height='23' align='RIGHT'>- </TD>
</TR>
<TR height='30'>
  <TD width='175' height='23' align='CENTER'> 합 계</TD>
  <TD width='78' height='23' align='RIGHT'>5,847,674 </TD>
  <TD width='78' height='23' align='RIGHT'>1,360,795 </TD>
  <TD width='78' height='23' align='RIGHT'>418,196 </TD>
  <TD width='81' height='23' align='RIGHT'>27,213,146 </TD>
  <TD width='81' height='23' align='RIGHT'>973,833 </TD>
  <TD width='81' height='23' align='RIGHT'>1,246,663 </TD>
</TR>
</TBODY>
</TABLE>
<P class='pgbrk'></P>
<P>(4) 당기와 전기 중 특수관계자와의 자금거래 내역은 다음과 같습니다. <BR/><BR/></P>
<P>&lt;당기&gt;                         &r
<TABLE class='nb' width='815'>
<COLGROUP>
<COL width='815'></COL>
</COLGROUP>
<TBODY>
<TR height='30'>
  <TD width='806' height='23' align='RIGHT' valign='TOP'>(단위 : 천원)</TD>
</TR>
</TBODY>
</TABLE>
<TABLE border='1' width='817'>
<COLGROUP>
<COL width='181'></COL>
<COL width='106'></COL>
<COL width='112'></COL>
<COL width='105'></COL>
<COL width='105'></COL>
<COL width='104'></COL>
```

✗ 특수관계자 현황, 우발채무, 종속기업 거래 현황 등
필요한 항목을 추출해야 하는데
우리가 다뤄야 하는건 통 HTML

심지어 회사마다 양식이 조금씩 다른..

단일 LLM 호출의 문제점

HTML 보고서
DART 공시

→

LLM 호출
Gemini / GPT

→

JSON 결과
구조화 출력

→

DB 저장
바로 사용

PoC에서는 작동한다. Production에서는 작동하지 않는다.

단일 LLM 호출의 문제점

HTML 보고서
DART 공시

→

LLM 호출
Gemini / GPT

→

JSON 결과
구조화 출력

→

DB 저장
바로 사용

단일 LLM 향상 시도

→ 더 큰 모델

→ 더 정교한 프롬프트

→ 더 많은 few-shot 예시

✗

엣지케이스는 계속 새로 발견됨.

한 케이스 잡으면 두 개 새로 나옴.

PoC에서는 작동한다. Production에서는 작동하지 않는다.

실제 데이터: 100만 보고서 = 100만 엣지케이스

CATEGORY A

데이터 표기 다양성

금액 단위 혼재

1억 5천만원 / 150,000,000 / 150백만 / 1.5억 — 같은 값 4가지 이상 표기

날짜 포맷 폭증

maturity_date 한 컬럼에서만 16,124가지 비표준 포맷 (만기일, '24.3.31, 2024-03 등)

인코딩·표기 오류

"\x10\x10", "닾기"(닿기 오타), 한글 자모 분리, 전각/반각 혼용

CATEGORY B

문서 구조 다양성

표 구조 변형

rowspan / colspan, 병합 셀, 다단 헤더, 좌우 이중 축 — 같은 의미가 매번 다른 모양

섹션·테이블 분할 변동

한 보고서에 동일 항목이 N개 표로 쪼개지거나 합쳐짐, 목차 계층도 보고서마다 상이

주석·참조 마크업

(주1), (*), 〃, — 값이 아닌 주석만 있는 셀, 각주가 본문 의미를 결정

CATEGORY C

의미·시간 변동

맥락 오인 / 환각

data_period에 "발행일: 2019-03-28", period_to=2042, USD 300,000 임의 환산

정정공시 버저닝

동일 보고서 rcept_no가 N회 정정 — is_latest, 변경분 추적, 이전 추출본 무효화 처리

스키마·프롬프트 진화

컬럼 추가/단위 변경, 프롬프트 v1→v2 재추출 — 추출 결과의 시점 일관성 관리 필요

문제는 LLM의 정확도가 아니라 — 데이터 표기 · 문서 구조 · 시간 변동의 다양성

1M+	10.15M	90%	99.9%
DART 공시 보고서	추출 데이터 행	비용 절감	원본 대비 정확도

"LLM 호출 한 번"으로는 도달할 수 없는 숫자들

하네스 == 눈물과 삽질과 밤샘의 누적으로 쓰여진 그 무언가

누적 가능한 결정론적 구조물

→ raw 보존 + GENERATED 자동 정규화

→ 룰베이스 검증 → 분류 → 수정/재추출

→ 이력 보존 + 가역적 변경

→ 도메인별 plug-in 가능한 골격

이 구조물들의 집합 == **Harness.**

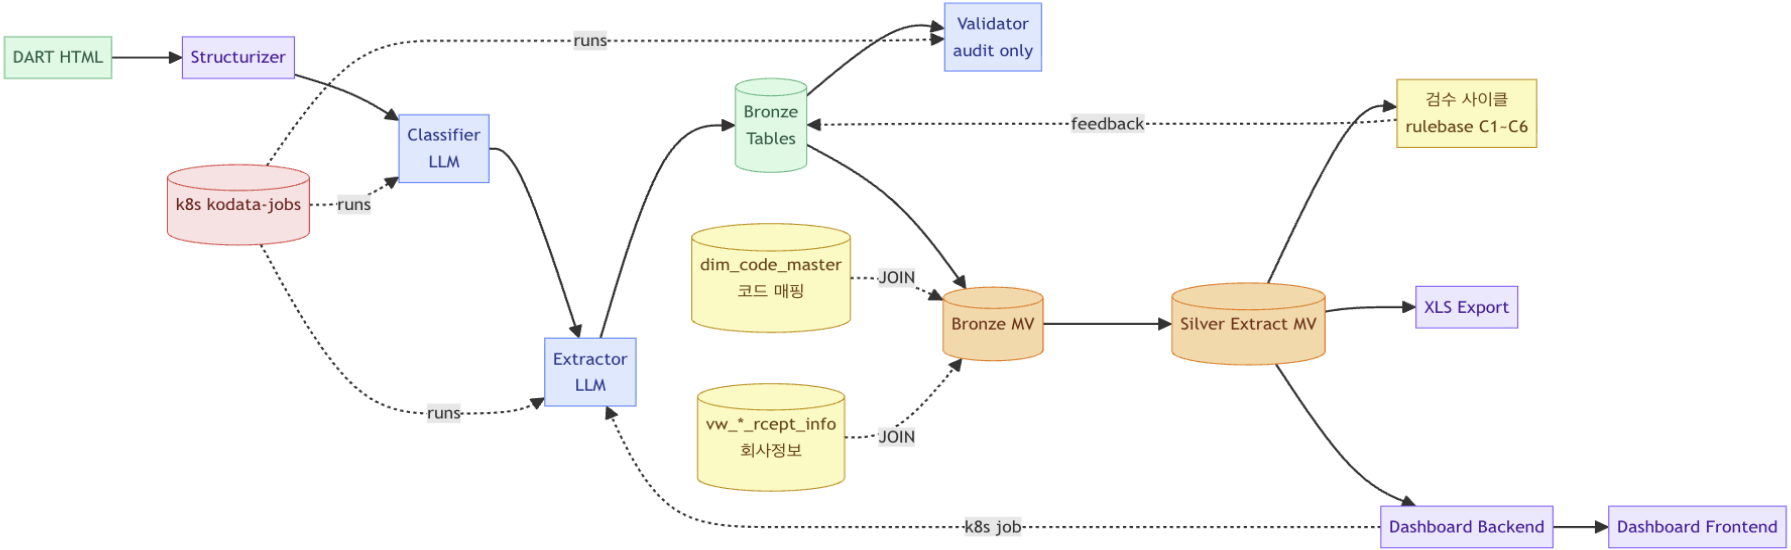

하네스 == 눈물과 삽질과 밤샘의 누적으로 쓰여진 그 무언가

Extractor
LLM

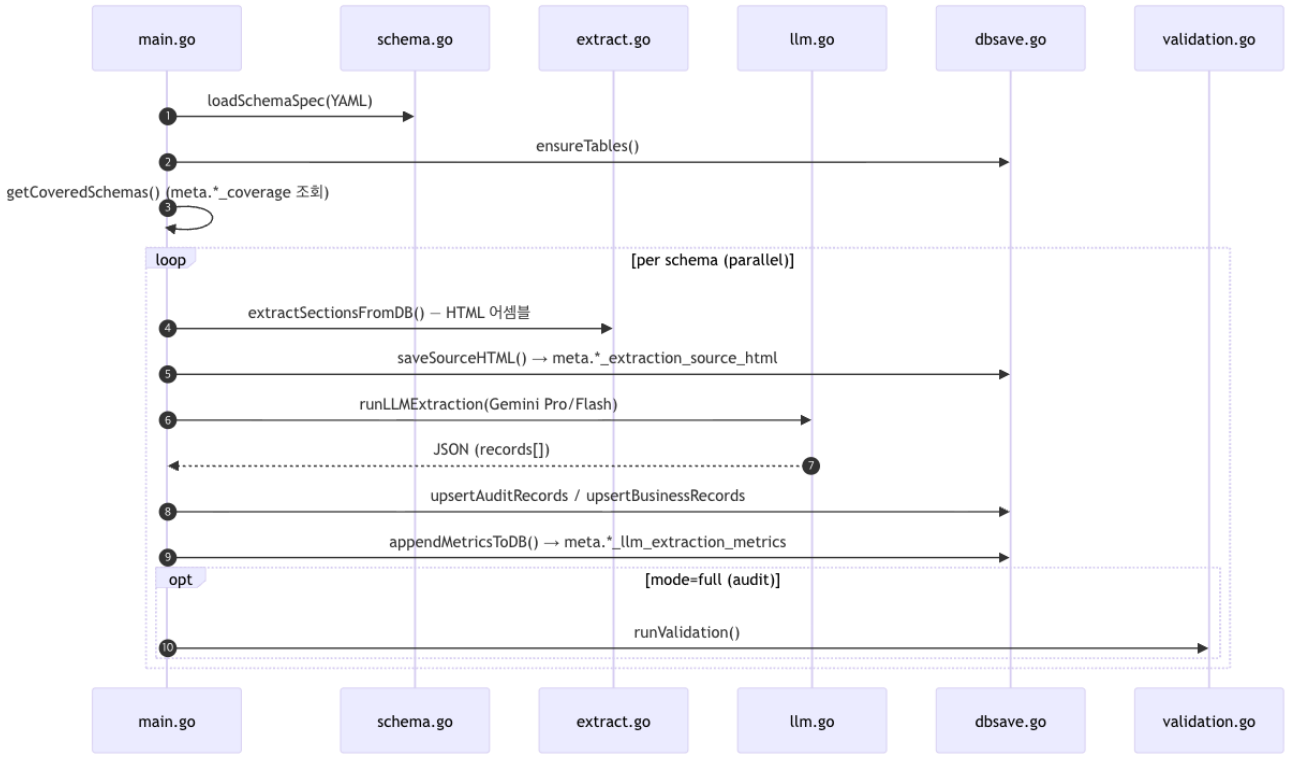

SECTION 02

Try and Error Log

추상화라는 개념과 친해지기

"100만 엣지케이스에서 공통점 추출하기"

추상화 — 변하는 것 뒤의 변하지 않는 것

DEFINITION

여러 구체 사례에서 **변하지 않는 본질·형태**를 뽑아 내고,
하나의 **규격**으로 묶어 내는 것

PM

" 이번에 고객사에서 신규 화면 요청이 들어왔어요"

(간단한 추가 사항인데 시간이 왜 걸리지..?)

개발자

" 어.. 이건 좀 시간이 걸릴 것 같은데요?”

(이 데이터를 추가하면 데이터 모델링 부터 다시 해야 되는데...)

추상화 없이 만들어진 시스템의 위험

변경 요청

화면 수정

시스템 일부 갈아엎기

"데이터 구조가 안 맞아"

데이터 항목 추가

테이블·화면 모두 재작업

"이전 화면들도 영향"

새 보고서 종류

사실상 새 시스템 구축

"수개월 + 리스크"

추상화 — 변하는 것 뒤의 변하지 않는 것

변하는 것 – 문서 구조는 회사마다 다름

문서 A
표 5개
다단 헤더

문서 B
표 1개
섹션 3개

문서 C
섹션 50개
3단계 계층

문서 D
표 0개
본문 위주

문서 N
정정공시
각주 다수

↓ 모든 문서의 공통점만 뽑으면

변하지 않는 것 – 모든 문서가 공통으로 가지는 두 가지

① **section_list**

"섹션을 한 줄씩 평탄하게 펼친 목록" — 어떤 문서든 결국 **번호 매겨진 섹션의 나열**

seq	block_type	title
1	header	회사 개요
2	paragraph	설립 배경
3	header	주요 사업
4	table	매출 구성
5	header	재무 정보
6	table	대차대조표
...	...	...

SCHEMA `seq_no · block_type · title · html`

② **hierarchy**

"섹션끼리의 부모-자식 관계" — 어떤 문서든 결국 **seq_no가 가리키는 트리**

```
root
├ 1 회사 개요
│   ├ 2 설립 배경
├ 3 주요 사업
│   └ 4 매출 구성 [표]
└ 5 재무 정보
    └ 6 대차대조표 [표]
```

SCHEMA `seq_no · parent_seq_no · depth_level`

SECTION 02

추상화 — 변하는 것 뒤의 변하지 않는 것

- 원래 DART HTML은 **회사마다 구조가 다르고, 제목 표기와 마크업도 제각각**

하지만 아무리 다른 문서가 와도, 모든 문서는 **section_list + hierarchy**를 가진다

- 이러한 추상화를 기반으로 structurizer가 HTML을

> section_list | hierarchy | section_html | cand_schemas

같은 **중간 표현**으로 구조화.

- 그 순간부터 downstream은 "HTML 파서"처럼 일하지 않고,

"정규화된 섹션 집합을 처리하는 엔진"처럼 작용

SECTION 03

Try and Error Log

룰베이스의 중요성 잊지 않기

”1.01을 무한히 곱하면 무한대에 이른다"

SECTION 03

Rule Base로 점점 커지는 엔트로피 낮추기

핵심은 raw HTML을 바로 추출하지 않고, 규칙 기반으로 섹션 경계를 만들어 downstream이 읽을 공통 문서 모델(section_list / hierarchy)로 바꾸는 것 → 이때 이 섹션 리스트 추출을 Rule Base로 실행

1. Raw HTML

- DART HTML
- <P>, <BR>, <TABLE> 혼재
- 회사별 포맷 차이 큼

2. rule_toc

- 정규식으로 depth 0/1/2 인식
- TABLE 내부는 기본 skip
- title + parent + marker + offset 생성

3. split

- marker/offset으로 원문 위치 재탐색
- start_i ~ start_(i+1) 절단
- section별 html 생성

4. upload

- section_list 저장
- hierarchy 저장
- Business는 cand_schemas도 같이 저장

5. downstream

- Classifier는 section만 읽음
- Extractor는 HTML 태그 세부사항을 몰라도 됨
- 문서 표현과 추출 책임 분리

section_i.html = original_html[start_i : start_(i+1)]

marker/offset 기반으로 원문 HTML을 잘라서 Section List를 만든 다음 다시 모았을 때 온전한 원문이 되도록.

SECTION 04

Try and Error Log

구조적인 사고하기

" 처음부터 이렇게 만들수는 없었을까"

만들기 전부터 고려했어야 하는 것

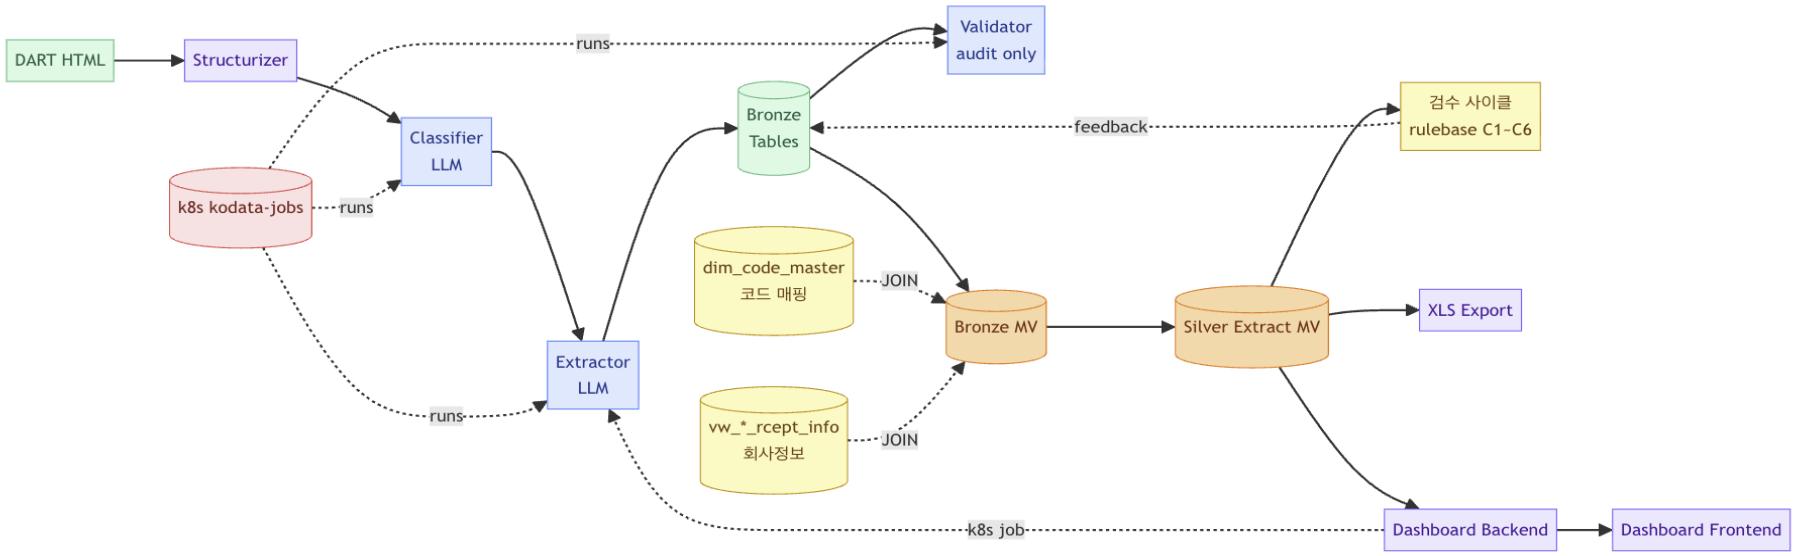

1 프로젝트 구조화	2 추상화	3 단계별 오류율 추적	4 멱등성 고려
5 비용 추적	5 MV 특성 정의	6 검수 자동화	7 지식 남기기

SECTION 05

Try and Error Log

Knowledge-Context

"구조적인 사고하기를 시스템화 하기"

시스템적으로 모든 팀원의 이해도를 높일수는 없을까

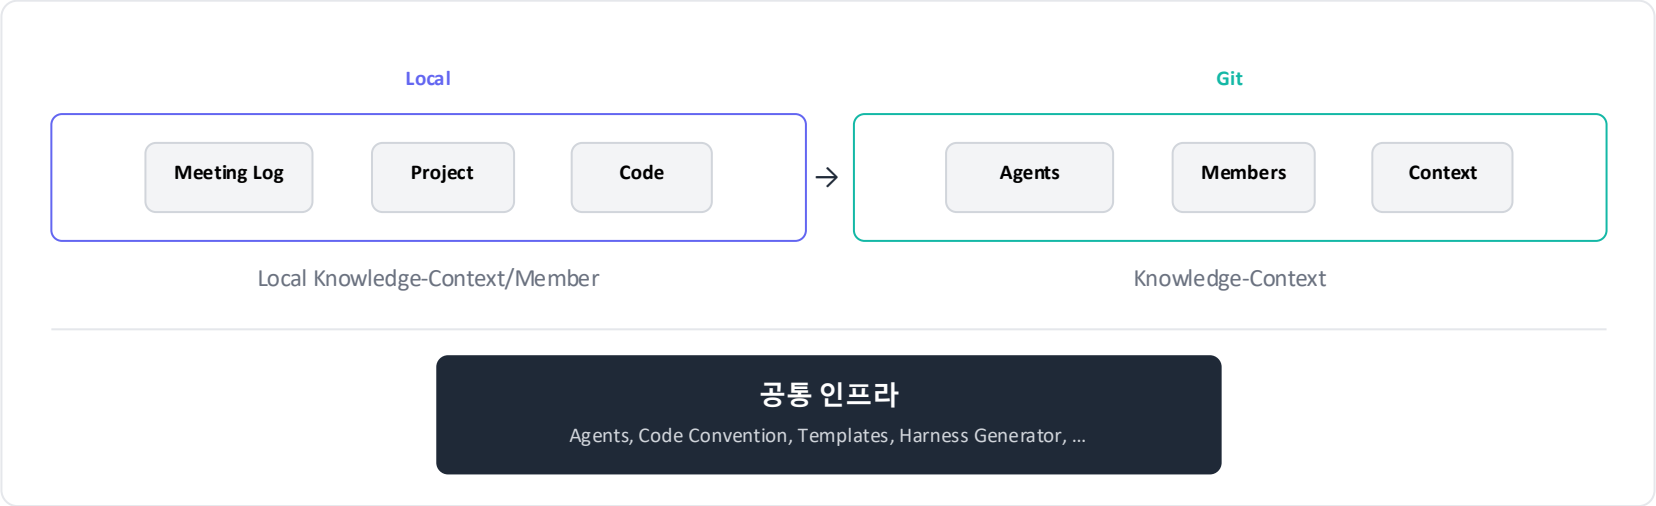

- 팀원들은 하루 한 번 로컬에서 깃으로 커밋&푸시
- 하루동안의 작업, 진척율 등이 깃 지식 저장소에서 자동 정리
- 새로운 프로젝트와 유사한 기존 프로젝트 깃에서 주요 로직 추출 → 초기 하네스 구축

Q&A